

北京理工大学大学生创新训练项目计划申请书

项目编号			
项目名称	【信息】Agent 赋能的视频关系理解		
项目负责人	李明翰	联系电话	13388016701
所在学院	计算机学院		
学号	1120240579	专业班级	计算机科学与技术（拔尖班）
指导教师	吴心筱		
E-mail	3572629910@qq.com		
申请日期	2025 年 11 月 27 日		
项目期限	一年期		

北京理工大学 教务处



填写说明

1. 本申请书所列各项内容均须实事求是，认真填写，表达明确严谨，简明扼要。
2. 申请人可以是个人，也可为创新团队，首页只填负责人。“项目编号”一栏不填。
3. 本申请书为大 16 开本（A4），左侧装订成册。可网上下载、自行复印或加页，但格式、内容、大小均须与原件一致。
4. 负责人所在学院认真审核，经初评和答辩，签署意见后，将申请书（一式两份）报送 xx 大学项目管理办公室。

一、 基本情况

项目名称	【信息】Agent 赋能的视频关系理解						
所属学科	学科一级类： 工学 学科二级类： 计算机类						
项目来源	☐ A、学生自主选题，来源于自己对课题的长期积累与兴趣 ☒ B、学生来源于教师科研项目选题 ☐ C、学生承担社会、企业委托项目选题 ☐ D、拔尖专项 ☐ E、竞赛专项 ☐ F、研修专项						
申请金额	3000.00 元	项目期限	一年期	拟申报项目级别			
负责人	李明翰	性别	男	民族	汉族	出生年月	2006 年 3 月
学号	1120240579	联系电话	宅： 13388016701 手机： 13388016701				
指导教师	吴心筱	联系电话	宅： 手机： 13811300895				
项目简介	视频关系理解是计算机视觉与人工智能交叉领域的前沿课题，其目标不仅是识别视频中的物体，更要精准定位并解析物体之间复杂的时空与交互关系（如“人正在追逐狗”、“某人将球扔向另一个人”）。当前，构建此类模型的核心瓶颈在于缺乏大规模、高质量的细粒度关系标注数据集，而传统人工标注方法成本极高、效率低下，且难以保证一致性。 本项目旨在突破这一瓶颈，探索并构建一套基于多模态智能体（Agent）的自动化视频关系理解与标注 workflow。项目核心思想是模仿人类认知过程，将复杂的视频理解任务分解为“感知-关联-推理-校验”等多个子任务，并交由具备专项能力的 Agent 协同完成。具体而言，系统将集成最先进的检测模型（如 DINO-X）进行帧级物体定位，利用在线/离线追踪算法（如 OC-SORT）构建跨帧的物体轨迹，最后驱动多模态大语言模型（如 GPT-4o、Qwen-VL）对轨迹片段进行深度推理，生成结构化的关系三元组。在此基础上，本项目将构						



		建一个视频关系理解评测基准，系统性地评估与对比主流大模型与专用模型在此任务上的性能优劣，为后续研究提供可靠的实验平台与数据支撑。				
负责人曾经参与科研的情况		本人具备扎实的 Python 编程能力与良好的数据结构基础，曾在校内课程设计与课外实践中承担核心开发任务，积累了解决复杂工程问题的初步经验。 为胜任本项目，我已投入时间进行前瞻性的技术准备与自主探索：系统性地梳理了与视频理解、目标检测及多模态大模型相关的技术文献与开源项目；完成了关键工具链（如 PyTorch, OpenCV）的学习与环境配置；尝试对多个主流模型 API 的调用与测试。通过这些准备，我快速了解了本项目所需的技术栈，并展现了较强的自主学习与工程实现能力。 我深知自身在正式科研经历方面尚有不足，但通过上述充分的准备，我已对项目技术路线建立了清晰的理解，并具备了开展本项目所需的实践基础。我相信能够在指导老师的帮助下，与团队成员协作，顺利完成项目目标。				
指导教师承担科研课题情况		本项目的指导教师吴心筱教授长期从事机器学习、计算机视觉、人工智能、图像视频内容理解等领域的前沿研究，具有深厚的学术积累和丰富的科研指导经验，目前负责国家自然科学基金，为本项目的顺利开展提供了坚实的理论支撑和前沿的学术视野。				
指导教师对本项目的支持情况		指导教师将在项目全程提供关键技术指导，定期参与项目研讨，协助攻克技术难点；同时，依托其承担的国家自然科学基金项目，为本研究开放课题组的 GPU 计算服务器资源，保障模型训练与推理的算力需求，并提供相关视频数据资源与标准数据集的使用指导；此外，还将在学术论文撰写、成果凝练及答辩准备等方面给予专业指导。				
项目组主要成员	姓名	学号	学院	专业班级	联系电话	项目分工
	李明翰	1120240579	计算机学院	计算机科学与技术（拔尖班）	13388016701	多模态 Agent workflows 设计与集成；主导论文撰写与 PPT 答辩

	吴泽宇	1120241125	计算机学院	人工智能（徐特立英才班）	15900783818	评测基准构建与可视化开发；参与实验评估与PPT制作
	张雨萌	1120242643	计算机学院	人工智能	18646909009	目标检测与轨迹追踪模块开发；参与实验数据整理与分析
	黄滢睿	1120242793	徐特立学院	未来精工技术	18470582663	多模态关系生成与抽取实现；参与论文核心章节撰写
指导教师	姓名	工号	学院/单位	职称	联系电话	电子邮件
	吴心筱	6120110104	计算机学院	教授	13811300895	wuxinxiao@bit.edu.cn

二、 立项依据（可加页）

（1）研究目的

1. 构建自动化标注系统

设计并实现一个端到端的、由多模态 Agent 驱动的视频关系自动标注系统，显著降低对大规模人工标注的依赖，提升数据集构建效率。

2. 探索 Agent 协同机制

深入研究多模态 Agent 在复杂视频理解任务中的协同工作模式，包括任务规划、模块调用、结果反思与自我修正等机制，提升系统的鲁棒性与准确性。

3. 建立领域评测基准

创建一个包含多种关系类型、场景复杂度的视频关系理解评测基准与数据集，为学术界和工业界提供一个公平、统一的性能评估平台。

4. 推动模型性能边界

利用自产的高质量数据，训练或微调专用模型，并与通用大模型进行对比分析，明确当前技术的优势与局限，推动视频关系理解模型性能的提升。

(2) 研究内容

1. 视频关系的形式化定义与任务分解

深入研究视频关系（静态空间关系、动态交互关系等）的语义层次与时空特性，为 Agent workflow 提供清晰的任务定义和分解逻辑。

2. 基于检测与追踪的视觉感知基础构建

研究并集成先进的开放词汇检测模型（如 DINO-X），实现视频帧中各类物体的精准定位与分类。

研究并应用多目标追踪算法（如 OC-SORT），将离散的检测框关联为连续一致的物体轨迹，为关系分析提供时空上下文。

3. 基于多模态大模型的关系推理与生成

研究针对视频片段（含轨迹标注）的关系描述生成技术，利用大模型的视觉-语言能力生成自然语言描述。

研究基于提示工程（Prompt Engineering）的关系抽取技术，从生成的描述或直接从视觉特征中结构化地提取关系三元组（主体，关系，客体）。

4.多模态 Agent 工作流的设计与实现

设计具备规划、执行、反思能力的 Agent 架构，使其能够自动调度检测、追踪、关系推理等模块，并对中间结果的冲突或不一致性进行识别与修正，实现闭环优化。

5.评测基准构建与系统性评估

设计全面的评估指标（如关系检测准确率、召回率、时空定位精度等），在构建的数据集上对比分析通用大模型（GPT-4o, Gemini）与自研流程的性能。

6.可视化与人工校验接口开发

开发可视化工具，将自动生成的关系以可视形式（如高亮轨迹、关系标签）叠加于视频上，便于人工进行结果校验、错误分析和数据清洗。

（3）国、内外研究现状和发展动态

1.国外研究现状

视频关系理解（Video Visual Relationship Detection, VideoVRD）是图像关系检测在时序维度上的延伸。早期工作如《ViP-CNN: Visual Video Person-Object Interaction

Detection》等主要依赖于全监督训练，需预先定义封闭的关系类别集合，泛化能力有限。近年来，随着多模态大模型（LMMs）的崛起，开放词汇（Open-Vocabulary）视频关系检测成为新趋势。例如，Google Research 提出的系列工作探索了如何利用 CLIP 等视觉语言模型进行零样本关系识别。

在技术路径上，主流方法可分为两类：一是基于轨迹预关联的方法，即先完成物体追踪，再对轨迹片段进行关系分析，此法稳定性高但依赖追踪质量；二是基于时空注意力机制的端到端方法，直接在视频中联合建模物体与关系，计算复杂度高但可能捕获更细微的交互。在 Agent 技术方面，从 ReAct、Reflexion 到 Voyager，研究表明 LLM 具备强大的任务规划与工具调用能力，但其应用目前主要集中在文本和游戏领域，与视频多模态理解的深度融合尚处于探索初期。

2. 国内研究现状

国内学术界与工业界在此领域亦进展迅速。高校如清华大学、北京大学在视频内容分析、行为识别等方面有深厚积累。企业如阿里巴巴、百度、智谱 AI 等发布的多模态大模型（如 Qwen-VL、文心一言、VisualGLM）均已具备强大的图像理解与描述能力，并开始向视频模态扩展。然而，国内研究工作目前更多聚焦于通用视频描述或动作识别，针对细粒度、结构化关系理解，特别是引入 Agent 架构实现自动化处理的系统性研究仍较为罕见。2023-2024 年，诸如《End-to-end Open-Vocabulary Video Visual Relationship Detection with Multimodal Prompting》等研究开始系统地利用视频-文本对齐能力，直接从未标注视频中预测开放的关系集合。

3. 发展动态与待解问题

趋势一：从封闭集到开放世界。研究重点正从预定义关系转向利用大模型理解无限

可能的开放词汇关系。趋势二：从感知到认知。单纯的特征提取已不足以应对复杂关系，需要引入具备推理能力的认知模型（如 Chain-of-Thought）。趋势三：自动化与智能化。利用 Agent 技术降低人工干预，构建自驱动的数据标注与模型迭代闭环，是解决数据稀缺问题的根本方向。

核心挑战：①长时序依赖建模：视频中的关系往往跨越长时间，如何有效建模长程时空依赖是关键。②轨迹碎片化与身份切换：遮挡、快速运动导致的追踪失败会严重影响后续关系推理的连贯性。③关系歧义性：同一段视觉内容可能对应多种合理解释，如何确保关系推理的准确性与合理性。④计算效率：对大模型进行频繁调用以及对长视频进行处理，面临巨大的计算开销挑战。

本项目正是在此背景下，旨在通过融合“先进检测追踪-大模型推理-Agent 协同控制”这一技术栈，系统性应对上述挑战。

（4）创新点与项目特色

1. 架构创新

模块化多模态 Agent 工作流：首次将具有规划-执行-反思-修正能力的智能体架构系统性地引入视频关系理解全流程，实现从原始视频到结构化关系数据的自动化、闭环生产，超越现有孤立模块拼接的范式。

2. 方法创新

轨迹增强的开放词汇关系检测：提出一种将物体轨迹作为首要时空上下文注入多模态大模型提示的方法，强化模型对物体动态交互的感知，显著提升对“靠近”、“远

离”、“传递”等动态关系的识别精度。

3. 范式创新


基于 Agent 自我校验的数据质量提升机制：设计 Agent 驱动的跨模块一致性校验机制（如利用大模型验证检测与关系结果的逻辑一致性），实现对中间结果的自动筛选、质疑与修正，逐步提升输出数据的可靠性。

4. 贡献创新

可复现的开放评测基准与数据集：项目产出的不仅是一个系统，更是一个包含高质量标注数据、标准化评估指标与基线模型的公开基准，旨在推动领域内研究的一致性与可比性。

（5）技术路线、拟解决的问题及预期成果

1. 技术路线图



2.拟解决的关键问题

视觉基础不稳固导致的误差传递：解决因遮挡、光照变化、小物体等导致的检测框漏检、误检，以及追踪过程中的轨迹碎片化与身份切换（ID Switch）问题。解决方案：通过 Agent 的反思机制，利用时序上下文信息和大模型的全局理解能力，对可疑的检测与追踪结果进行校验和修正。

关系推理的语义歧义与幻觉：解决多模态大模型在生成关系时可能出现的“幻觉”问题，即生成视频中不存在的关系，或对复杂动态关系描述不准确。解决方案：采用“轨迹增强的提示”方法，将物体轨迹作为关键视觉线索提供给模型；同时，通过多方法结果对比与 Agent 仲裁，筛选出最合理的关系。

自动化系统的效率与稳定性：解决长视频处理中计算开销大、流程长导致的效率低下问题，以及模块间衔接不稳定可能导致的系统崩溃。解决方案：进行关键工程优化，如自适应关键帧采样、异步并行处理、缓存机制等，并设计健壮的 Agent 控制流，确保系统能够稳定运行。

（6）项目研究进度安排

本项目将采用“分阶段、模块化”的策略，从基础环境搭建到最终系统验证，逐步推进。核心思想是构建一个“感知-认知-控制”三层结构的智能体系统。

第一阶段：环境准备与技术预研（第 1 个月）

目标：奠定项目开发与实验的理论与实践基础。

任务与扩展：

1. 环境搭建：配置 Python、PyTorch、CUDA 等深度学习环境，注册并熟悉所需 API（如国内豆包、Qwen-VL，国际 OpenAI 等）。
2. 数据准备：下载并熟悉公开视频关系数据集（如 VIDOR, ActionGenome）的数据结构、标注格式与评估指标。
3. 技术预研：精读《End-to-end open-vocabulary video visual relationship detection》等核心论文，理解任务前沿。运行 DINO-X、OC-SORT 等模型的开源 Demo，了解其输入输出格式与性能表现。

产出：详尽的文献综述报告、可用的开发环境、核心 API 调用示例代码。

第二阶段：核心模块实现与验证（第 2-5 个月）

目标：独立实现并验证系统三大核心模块的功能。

任务与扩展：

1. 视觉感知模块（框级别的标注）

方法：基于 DINO-X 模型，对视频进行均匀采样或关键帧提取，完成每帧图像的开放词汇目标检测，获取物体类别与边界框。



验证：在单张图像和视频帧上评估检测精度与泛化能力。

2. 轨迹关联模块（轨迹追踪）

方法：将 DINO-X 产生的逐帧检测框作为输入，采用 OC-SORT 算法进行跨帧关联，为每个物体生成连续、唯一的轨迹 ID。

验证：在短视频序列上评估追踪的准确性，重点关注身份切换（ID Switch）和轨迹碎片化问题。

3. 关系推理模块（关系分类）

方法：①（描述生成+抽取）采用滑动窗口（如 30 帧，重叠 15 帧）截取视频片段，并叠加轨迹框可视化。使用多模态大模型（如 Qwen-VL）生成该片段的自然语言描述，随后利用纯文本 LLM 从描述中抽取结构化关系三元组。②（直接推理）：设计精妙的 Prompt，直接让多模态大模型聚焦于指定的轨迹对，判断其是否存在特定关系（如静态位置、动态动作等）。

验证：对比两种方案的优劣，对生成的关系进行人工抽样检查，评估准确率。

产出：三个可运行的、经过初步验证的功能模块。

第三阶段：智能体 workflow 集成（第 6-7 个月）

目标：引入智能体（Agent）的控制逻辑，将离散模块集成为自动化的闭环系统。

任务与扩展：

1. workflow编排：设计 Agent 的核心控制逻辑，使其能按顺序自动调用检测、追踪、关系推理模块。

2. 规划与反思机制实现：

规划： Agent 根据视频长度自动决定采样频率和滑动窗口策略。

反思：①大模型验证：实现初步的反思循环。例如，当关系推理模块识别出“2 个滑板”但轨迹 ID 只有一个时，触发大模型对视频片段进行整体计数。若计数结果为 1，则 Agent 可判定该段轨迹存在“同一物体 ID 分裂”问题，并反馈给追踪模块或启动重检测。②关系一致性校验：对生成的关系进行对比，当结果冲突时，Agent 可设计 Prompt 让大模型进行仲裁或重新推理。

产出：首个端到端的自动化标注系统原型，具备基础的自我校验能力。

第四阶段：系统优化与评测基准构建（第 8-9 个月）

目标：提升系统鲁棒性与效率，并构建量化评估体系。

任务与扩展：

1. 系统优化：在效率方面：针对长视频，优化处理流程（如更高效的关键帧采样、异步调用）。在鲁棒性方面：完善针对遮挡、复杂场景的处理逻辑，强化 Agent 的反思与修

正能力。

2. 可视化工具开发：开发工具，将最终关系标注（三元组）与物体轨迹以可视化形式（如高亮框、轨迹线、关系标签）叠加在视频上，用于结果检查和后续人工筛选。

3. 评测基准构建：利用本系统，对一批未标注视频进行自动化处理，产出一批带有关系标注的数据。设计评估指标（如关系检测 mAP、追踪精度 MOTA、关系分类准确率等）。

产出：优化的系统 V2.0、可视化工具、内部评测基准与初步的标注数据集。

第五阶段：实验评估与成果固化（第 10 个月）

目标：系统评估项目成果，完成总结。

任务与扩展：

1. 对比实验：在构建的评测基准上，运行主流大模型（如 GPT-4V, Gemini）进行零样本关系理解，并与本系统的性能进行对比分析。

2. 成果固化：整理所有代码、数据、实验记录，撰写项目结题报告或学术论文初稿。

产出：完整的实验报告、项目结题报告/论文初稿、最终的可交付代码与数据。



(7) 已有基础

1. 与本项目有关的研究积累和已取得的成绩

项目组成员已熟练掌握 Python 编程，有初步使用 PyTorch 深度学习框架，具备扎实的算法实现与调试能力。在项目预备阶段，团队已完成了初步的学术调研，明确了以 DINO-X、OC-SORT 和多模态大语言模型为核心的技术路线图，并对相关开源代码库进行了初步调研与测试。此外，团队成员已成功调用过国内主流大模型（如豆包、智谱 ChatGLM）的 API，积累了初步的多模态交互与提示工程经验。

2. 已具备的条件，尚缺少的条件及解决方法

已具备的条件。在理论基础方面，初步掌握深度学习、计算机视觉的基础知识。在技术准备方面，熟悉目标检测、多目标追踪等基本任务，并已识别出可行的开源模型方案。在开发能力方面，具备强大的代码实现与问题解决能力。在计算资源方面，可申请使用学校的高性能计算集群或云服务器资源。

尚缺少的条件及解决方法。①领域深度知识：对视频关系理解领域的最新前沿和细微挑战理解尚浅。解决方法：制定详细的论文阅读计划，重点精读 CVPR、ICCV 等会议近三年的相关论文，并定期组织小组讨论。②Agent 系统设计与实现经验：缺乏构建复杂 Agent 工作流的实际经验。解决方法：学习 LangChain、AutoGPT 等开源 Agent 框架的设计理念，从构建简单的文本 Agent

开始，逐步过渡到多模态场景。③大规模视频数据与计算经费：处理长视频和调用商用大模型 API 需要可观的计算与资金支持。解决方法：优先使用公开数据集（如 VIDOR, ActionGenome）进行开发与实验；积极申请学校“大学生创新创业训练计划”项目经费支持；优化算法，采用采样、缓存等策略降低 API 调用成本。

三、 经费预算

开支科目	预算经费 (元)	主要用途	阶段下达经费计划 (元)	
			前半阶段	后半阶段
预算经费总额	3000.00	Agent 赋能的视频关系理解	1800.00	1200.00
1. 业务费	2800.00	项目运行主要开支	1700.00	1100.00
(1) 计算、分析、测试费	2600.00	用于支付调用 GPT-4o、Qwen-VL 等多模态大模型 API 的费用。这是项目自动化标注流程的关键成本，需预留充足预算以处理足够数量的视频片段进行实验和基准构建。根据开题调研的“滑动窗口”策略，预计会产生大量 API 请求。	1600.00	1000.00
(2) 能源动力费	200.00	用于支付下载大型公开数据集（如 VIDOR, ActionGenome）的网络流量费，或购买小容量云存储空间（如阿里云 OSS）用于临时存放处理后的中间结果和标注数据。确保数据处理流程顺畅，避免因存储问题导致工作中断。	100.00	100.00
(3) 会议、差旅费	0.00	无	0.00	0.00

(4) 文献检索费	0.00	无	0.00	0.00
(5) 论文出版费	0.00	无	0.00	0.00
2. 仪器设备购置费	0.00	无	0.00	0.00
3. 实验装置试制费	0.00	无	0.00	0.00
4. 材料费	200.00	购买必要的办公耗材与数据存储装备。	100.00	100.00
学校拨款				
财政拨款				

四、项目组成员签名

李明翰	张雨萌	黄滢睿
吴泽宇		



北京理工大学

五、 指导教师意见

导师（签章）： 年 月 日

六、 院系推荐意见

盖 章： 年 月 日

七、 学校推荐意见

盖 章： 年 月 日
